Manejo y limpieza de datos

FSC

Contents

Antes de empezar... **1**

El ecosistema *tidyverse* **1**

Ejemplo motivacional: Gapminder foundation . . . 3
Paquete dplyr: *filter* y *select* . . . 4
Sumarizando data con *dplyr()* . . . 5
summarize() . . . 5
group_by() . . . 6
dot . . . 6
Ordenar data.frames: *arrange() top_n()* . . . 8
Ejercicio: NCHS Data . . . 10
Tidyverse conditionals . . . 11
`case_when` . . . 11
`between` . . . 11
Tidy data . . . 11
pivot_longer and *pivot_wider* . . . 14
Si los nombres de las columnas son numericos . . . 15
Variables dentro de los nombres de columna . . . 17
Varias observaciones por fila . . . 19
Ejercicios: tidy/wide . . . 20

Limpieza de datos: el paquete janitor **22**

tabyl better than table: adorn_() functions . . . 22
Ejemplo 1: mtcars . . . 23
Ejemplo 2: starwars . . . 23
Ejemplo 3: Modelos de coches . . . 25
Otras funciones del paquete janitor . . . 25
get_dupes() . . . 25
get_dupes() . . . 25
round_half_up() . . . 26
factores . . . 26
Map-reduce using R . . . 26

Antes de empezar...

Los materiales de esta clase han sido preparados utilizando dos libros que están disponibles bajo licencia OUP y que os invito a explorar:

Hands-on programming with R https://rstudio-education.github.io/hopr/

Data Science with R https://rafalab.github.io/dsbook/

El ecosistema *tidyverse*

Se trata de una colección de paquetes de R diseñados por Hadley Wickham específicamente para data science. Todos los paquetes comparten la misma filosofia, diseño, gramática y estructura.

Figure 1: Tidyverse

Todos los paquetes de *tidyverse* pueden instalarse de una vez con:

```
#install.packages("tidyverse")
```

Ejemplo motivacional: Gapminder foundation

La organización Gapminder trata de desenmascarar falsos mitos acerca del estado del mundo en terminos de pobreza, desigualdad, etc a través del uso de datos. Utilizando el dataset *gapminder* del paquete *dslabs* trataremos de contestar a dos preguntas:

1. Es cierto que el mundo se divide en paises occidentales ricos y no-occidentales pobres?
2. Han aumentado las diferencias entre paises en los últimos 40 años?

- Descargamos los datos:

```
library(dslabs)
data(gapminder)
#si no tienes el paquete instalado
#gapminder=read.csv("DataSets/Gapminder.csv")
```

*Exploramos los datos:

```
View(gapminder)
head(gapminder)
```

```
##               country year infant_mortality life_expectancy fertility
## 1             Albania 1960           115.40           62.87      6.19
## 2             Algeria 1960           148.20           47.50      7.65
## 3              Angola 1960           208.00           35.98      7.32
## 4 Antigua and Barbuda 1960               NA           62.97      4.43
## 5           Argentina 1960            59.87           65.39      3.11
## 6             Armenia 1960               NA           66.86      4.55
##   population          gdp continent          region
## 1    1636054           NA    Europe Southern Europe
## 2   11124892  13828152297    Africa Northern Africa
## 3    5270844           NA    Africa   Middle Africa
## 4      54681           NA  Americas       Caribbean
## 5   20619075 108322326649  Americas   South America
## 6    1867396           NA      Asia    Western Asia
```

```
str(gapminder)
```

```
## 'data.frame':    10545 obs. of  9 variables:
##  $ country         : Factor w/ 185 levels "Albania","Algeria",..: 1 2 3 4 5 6 7 8 9 10 ...
##  $ year            : int  1960 1960 1960 1960 1960 1960 1960 1960 1960 1960 ...
##  $ infant_mortality: num  115.4 148.2 208 NA 59.9 ...
##  $ life_expectancy : num  62.9 47.5 36 63 65.4 ...
##  $ fertility       : num  6.19 7.65 7.32 4.43 3.11 4.55 4.82 3.45 2.7 5.57 ...
##  $ population      : num  1636054 11124892 5270844 54681 20619075 ...
##  $ gdp             : num  NA 1.38e+10 NA NA 1.08e+11 ...
##  $ continent       : Factor w/ 5 levels "Africa","Americas",..: 4 1 1 2 2 3 2 5 4 3 ...
##  $ region          : Factor w/ 22 levels "Australia and New Zealand",..: 19 11 10 2 15 21 2 1 22 21
```

- De las siguientes parejas, cual dirias que tuvo la mayor mortalidad infantil en 2015?

++ Sri Lanka or Turkey

++ Poland or South Korea

++ Malaysia or Russia

++ Pakistan or Vietnam

++ Thailand or South Africa

Ahora, trata de responderlo usando los datos por medio de los comandos *filter* y *select*

Paquete dplyr: *filter* y *select*

filter se encarga de hacer *subsetting* de un data.frame, tibble o matriz mientras que *select* selecciona las columnas. Como cualquier otra función tidyverse el primer argumento tiene que ser el objeto que se va a manipular. A continuacion con *filter* se da una condicion logica que devuelve TRUE or FALSE para cada fila. Para *select* es suficiente con dar el nombre de la columna pero tambien pueden proporcionarse funciones como *starts_with()*, *ends_with()* o *contain()*. Si se quiere quitar una columna basta con poner un "-" delante.

Por ejemplo, usando filter and select podemos quedarnos solo con la informacion de mortalidad infantil en cada pareja de paises en el año 2015:

```
library(dplyr)
gapminder %>%
  filter(year == 2015 & country %in% c("Sri Lanka","Turkey")) %>%
  select(country, infant_mortality)
```

```
##     country infant_mortality
## 1 Sri Lanka              8.4
## 2    Turkey             11.6
```

```
gapminder %>%
  filter(year == 2015 & country %in% c("Poland","South Korea")) %>%
  select(country, infant_mortality)
```

```
##       country infant_mortality
## 1 South Korea              2.9
## 2      Poland              4.5
```

```
gapminder %>%
  filter(year == 2015 & country %in% c("Malaysia","Russia")) %>%
  select(country, infant_mortality)
```

```
##    country infant_mortality
## 1 Malaysia              6.0
## 2   Russia              8.2
```

```
gapminder %>%
  filter(year == 2015 & country %in% c("Pakistan","Vietnam")) %>%
  select(country, infant_mortality)
```

```
##    country infant_mortality
## 1 Pakistan             65.8
## 2  Vietnam             17.3
```

```
gapminder %>%
  filter(year == 2015 & country %in% c("Thailand","South Africa")) %>%
  select(country, infant_mortality)
```

```
##        country infant_mortality
## 1 South Africa             33.6
## 2     Thailand             10.5
```

Si queremos centrarnos en los paises de una cierta región para ver por ejemplo la media pero no nos acordamos del nombre exacto de la columna:

```
gp.reduced<-gapminder %>%
  filter(year == 2015 ) %>%
  select(country, starts_with("reg"), infant_mortality)

head(gp.reduced)
```

```
##               country          region infant_mortality
## 1             Albania Southern Europe             12.5
## 2             Algeria Northern Africa             21.9
## 3              Angola   Middle Africa             96.0
## 4 Antigua and Barbuda       Caribbean              5.8
## 5           Argentina   South America             11.1
## 6             Armenia    Western Asia             12.6
```

Sumarizando data con *dplyr()*

summarize()

Vamos a utilizar los datos de alturas del paquete dslabs

```
library(dslabs)
data(heights)
head(heights)
```

```
##      sex height
## 1   Male     75
## 2   Male     70
## 3   Male     68
## 4   Male     74
## 5   Male     61
## 6 Female     65
```

```
str(heights)
```

```
## 'data.frame':    1050 obs. of  2 variables:
##  $ sex   : Factor w/ 2 levels "Female","Male": 2 2 2 2 2 1 1 1 1 2 ...
##  $ height: num  75 70 68 74 61 65 66 62 66 67 ...
```

La función *summarize()* del paquete *dplyr* nos calcula cualquier agregado que le pidamos de un vector de un data.frame o de un tibble. Como el input era un data.frame() el output también lo es.

```
heights %>%
  filter(sex == "Female") %>%
  summarize(
    average = mean(height),
    standard_deviation = sd(height)
    )
```

```
##    average standard_deviation
## 1 64.93942           3.760656
```

Se pueden utilizar medidas mas robustas:

```
s <- heights %>%
  summarize(
    median = median(height),
    mad=mad(height),
    min=min(height),
```

```
    max=max(height))
s
```

```
##   median    mad min      max
## 1   68.5 3.7065  50 82.67717
```

```
str(s)
```

```
## 'data.frame':    1 obs. of  4 variables:
##  $ median: num 68.5
##  $ mad   : num 3.71
##  $ min   : num 50
##  $ max   : num 82.7
```

NOTA: con la función *summarize* solo podemos llamar funciones que devuelvan un solo valor.

group_by()

Si queremos hacer una operacion por grupos:

```
heights %>%
  group_by(sex) %>%
  summarize(
    average = mean(height),
    standard_deviation = sd(height)
    )
```

```
## # A tibble: 2 x 3
##   sex    average standard_deviation
##   <fct>    <dbl>              <dbl>
## 1 Female    64.9               3.76
## 2 Male      69.3               3.61
```

dot

Recordemos en el último ejercicio de la sesión II habiamos descargado la tabla con el rate de asesinatos en todo el mundo.

```
url="https://en.wikipedia.org/wiki/List_of_countries_by_intentional_homicide_rate"
h <- read_html(url)
class(h)
```

```
## [1] "xml_document" "xml_node"
```

```
h
```

```
## {html_document}
## <html class="client-nojs" lang="en" dir="ltr">
## [1] <head>\n<meta http-equiv="Content-Type" content="text/html; charset= ...
## [2] <body class="mediawiki ltr sitedir-ltr mw-hide-empty-elt ns-0 ns-sub ...
```

```
tab <- h %>% html_nodes("table")
tab <- tab[[4]] %>% html_table
head(tab)
```

```
##   Country (or dependent territory,subnational area, etc.) Region
## 1                                                 Burundi Africa
## 2                                                 Comoros Africa
## 3                                                Djibouti Africa
```

```
## 4                                                 Eritrea Africa
## 5                                                Ethiopia Africa
## 6                                                   Kenya Africa
##        Subregion Rate Count Yearlisted       Source
## 1 Eastern Africa 6.02   635       2016      CTS/SDG
## 2 Eastern Africa 7.70    60       2015 WHO Estimate
## 3 Eastern Africa 6.48    60       2015 WHO Estimate
## 4 Eastern Africa 8.04   390       2015 WHO Estimate
## 5 Eastern Africa 7.56 7,552       2015 WHO Estimate
## 6 Eastern Africa 5.00 2,466       2017          CTS
```

```
class(tab)
```

```
## [1] "data.frame"
```

```
tab <- tab %>%
  select(starts_with("Country"),
         Region,Count,Rate,starts_with("Year")) %>%
  setNames(c("country", "continent", "total", "murder_rate","year"))

head(tab)
```

```
##    country continent total murder_rate year
## 1  Burundi    Africa   635        6.02 2016
## 2  Comoros    Africa    60        7.70 2015
## 3 Djibouti    Africa    60        6.48 2015
## 4  Eritrea    Africa   390        8.04 2015
## 5 Ethiopia    Africa 7,552        7.56 2015
## 6    Kenya    Africa 2,466        5.00 2017
```

Para comparar USA (nuestros datos por estados en murders) necesitabamos primero hacer la media de todos los estados, calculando el ratio de asesinatos por 100.000 habitantes:

```
s <- murders %>%
  mutate(rate=total/population*100000) %>%
  summarize(mean(rate))
s
```

```
##   mean(rate)
## 1   2.779125
```

```
str(s)
```

```
## 'data.frame':    1 obs. of  1 variable:
##  $ mean(rate): num 2.78
```

Como las funciones de dplyr devuelven el mismo tipo de objeto que su input en este caso queremos acceder sólo al valor que tienen almacenado. Podemos hacerlo asi:

```
s
```

```
##   mean(rate)
## 1   2.779125
```

```
s$`mean(rate)`
```

```
## [1] 2.779125
```

```
s %>% .$`mean(rate)`
```

```
## [1] 2.779125
```

"." simplemente reemplaza al objeto que pasamos por el pipe, en este caso s que es n data frame. Por eso accedemos su información con $

```
s <- murders %>%
  summarize(rate=mean(total/population*100000)) %>%
  .$rate
s
```

```
## [1] 2.779125
```

```
s2<-murders %>%
  summarize(total=sum(total)) %>%
  .$total
s2
```

```
## [1] 9403
```

Construimos un objeto que contenga la informacion que teniamos de USA en el objeto tab, quedandonos solo con medidas del año 2015:

```
tab.USA<-tab %>%
  filter(year=="2015") %>%
  select(-year) %>%
  add_row(country = "USA",
          continent = "Americas",
          total = s2,
          murder_rate=s)
```

Ordenar data.frames: *arrange() top_n()*

¿Cual es el estado con mayor poblacion? La función *arrange()* ordena tablas enteras por una variable

```
tab.USA %>%
  group_by(continent) %>%
  summarize(mean.rate=mean(murder_rate)) %>%     arrange(desc(mean.rate))
```

```
## # A tibble: 5 x 2
##   continent mean.rate
##   <chr>         <dbl>
## 1 Americas     14.3
## 2 Africa        8.55
## 3 Asia          3.51
## 4 Oceania       3.4
## 5 Europe        0.235
```

```
tab.USA %>% filter(continent=="Americas") %>% arrange(murder_rate)
```

```
##               country continent total murder_rate
## 1                 USA  Americas  9403    2.779125
## 2            Paraguay  Americas   617    9.290000
## 3 Trinidad and Tobago  Americas   420   30.880000
```

```
murders %>% arrange(population) %>% head()
```

```
##                  state abb        region population total
## 1              Wyoming  WY          West     563626     5
## 2 District of Columbia  DC         South     601723    99
## 3              Vermont  VT     Northeast     625741     2
## 4         North Dakota  ND North Central     672591     4
```

```
## 5               Alaska  AK          West     710231    19
## 6         South Dakota  SD North Central     814180     8
```

¿Y con menor numero de asesinatos?

```
murders %>% arrange(total) %>% head()
```

```
##           state abb        region population total
## 1       Vermont  VT     Northeast     625741     2
## 2  North Dakota  ND North Central     672591     4
## 3 New Hampshire  NH     Northeast    1316470     5
## 4       Wyoming  WY          West     563626     5
## 5        Hawaii  HI          West    1360301     7
## 6  South Dakota  SD North Central     814180     8
```

¿Y en por cien mil habitantes?

```
murders %>% mutate(rate=total/population*100000)%>%
  arrange(rate) %>%
  head()
```

```
##           state abb        region population total      rate
## 1       Vermont  VT     Northeast     625741     2 0.3196211
## 2 New Hampshire  NH     Northeast    1316470     5 0.3798036
## 3        Hawaii  HI          West    1360301     7 0.5145920
## 4  North Dakota  ND North Central     672591     4 0.5947151
## 5          Iowa  IA North Central    3046355    21 0.6893484
## 6         Idaho  ID          West    1567582    12 0.7655102
```

Si tenemos empates podemos usar una segunda columna para deshacer dicho empate:

```
murders %>% mutate(rate=total/population*100000)%>%
  arrange(total,rate) %>%
  head()
```

```
##           state abb        region population total      rate
## 1       Vermont  VT     Northeast     625741     2 0.3196211
## 2  North Dakota  ND North Central     672591     4 0.5947151
## 3 New Hampshire  NH     Northeast    1316470     5 0.3798036
## 4       Wyoming  WY          West     563626     5 0.8871131
## 5        Hawaii  HI          West    1360301     7 0.5145920
## 6  South Dakota  SD North Central     814180     8 0.9825837
```

¿Y el mayor? Por último podemos seleccionar las primeras filas de un data.frame o de un tibble usando la función *top_n()*. Nota que la función *desc()* indica que se ordena de manera descendente el data.frame.

```
murders %>% mutate(rate=total/population*100000)%>%
  arrange(desc(rate)) %>%
  top_n(10)
```

```
## Selecting by rate
```

```
##                   state abb        region population total      rate
## 1  District of Columbia  DC         South     601723    99 16.452753
## 2             Louisiana  LA         South    4533372   351  7.742581
## 3              Missouri  MO North Central    5988927   321  5.359892
## 4              Maryland  MD         South    5773552   293  5.074866
## 5        South Carolina  SC         South    4625364   207  4.475323
## 6              Delaware  DE         South     897934    38  4.231937
## 7              Michigan  MI North Central    9883640   413  4.178622
```

```
## 8           Mississippi  MS         South    2967297   120  4.044085
## 9               Georgia  GA         South    9920000   376  3.790323
## 10              Arizona  AZ          West    6392017   232  3.629527
```

Ejercicio: NCHS Data

El National Center for Health Statistics ha realizado encuestas de habitos de vida y salud desde 1960. Desde 1999 5000 individuos han sido entrevistados cada año junto con una exploración medica. Parte de estos datos están en el paquete **NHANES**

```
library(NHANES)
```

```
## Warning: package 'NHANES' was built under R version 3.6.2
```

```
data(NHANES)
```

Los datos en el paquete **NHANES** contienen una gran cantidad de valores perdidos.Las principales funciones de sumarización de R devuelven un NA si hay NA en los datos.

```
data(na_example)
mean(na_example)
```

```
## [1] NA
```

```
sd(na_example)
```

```
## [1] NA
```

Para ignorar los valores perdidos usamos el argumento `na.rm`:

```
mean(na_example, na.rm = TRUE)
```

```
## [1] 2.301754
```

```
sd(na_example, na.rm = TRUE)
```

```
## [1] 1.22338
```

Vamos a explorar los datos en **NHANES**

1. Tensión sanguínea: Seleccionemos a las mujeres entre 20 y 29 años.`AgeDecade` es una variable categórica que contiene las edades. La categoría es " 20-29", con un espacio delante! Cual es su media? (`BPSysAve` variable). Guardalo en una variable llamada`ref`.

Hint: Usa `filter` y `summarize` y luego usa `na.rm = TRUE` al calcular su meda y desviacion estandard. Tambien podrias quitar los missing usando `filter`.

2. Usando pipe asigna ese valor a una variable llamada `ref_avg`. Hint: Use the code similar to above and then `pull`.
3. min y max para cada grupo de edad dentro de las mujeres
4. Media y desviacion estandar para cada grupo de edad. Hint: filtra por genero y luego usa `group_by`.
5. Hacer lo mismo para los hombres
6. Usando `group_by(AgeDecade, Gender)`, repite 4 y 5 con una sola linea de código.
7. Para los hombres entre 40-49 compara su presion sistolica para las distintas razas reportadas en la variable `Race1` y ordenalas de mayor a menor.

Tidyverse conditionals

case_when

```
x <- c(-2, -1, 0, 1, 2)
case_when(x < 0 ~ "Negative",
          x > 0 ~ "Positive",
          TRUE ~ "Zero")
```

```
## [1] "Negative" "Negative" "Zero"     "Positive" "Positive"
```

Imaginemos que queremos comparar los rates de asesinatos en tres regiones: *New England*, *West Coast*, *South*, y *other*. Para cada estado necesitamos preguntar si es de cada uno de ellos y si no pasar al siguiente:

```
data(murders)
murders %>%
  mutate(group = case_when(
    abb %in% c("ME", "NH", "VT", "MA", "RI", "CT") ~ "New England",
    abb %in% c("WA", "OR", "CA") ~ "West Coast",
    region == "South" ~ "South",
    TRUE ~ "other")) %>%
  group_by(group) %>%
  summarize(rate = sum(total) / sum(population) * 10^5) %>%
  arrange(rate)
```

```
## # A tibble: 4 x 2
##   group        rate
##   <chr>       <dbl>
## 1 New England  1.72
## 2 other        2.71
## 3 West Coast   2.90
## 4 South        3.63
```

between

```
x >= a & x <= b
```

Utilizando tidyverse:

```
between(x, a, b)
```

Tidy data

Los datos están en formato tidy si la información de una o varias columnas constituyen una clave única para cada dato, frente a los datos de tipo "wide" para los que dicha clave viene dada por los nombres o identificadores de filas y columnas, haciendo complicado tener claves constituidas por mas de tres campos.

gapminder es un data.frame *tidy*: para cada pais y año tenemos información de varios indicadores como mortalidad infantil, fertilidad, esperanza de vida, etc.

Fácilmente, gracias a que los datos están en formato *tidy* podemos usar el paquete ggplot2 para comparar la evolucion de la fertilidad y la esperanza de vida en Europa y Asia y así responder a las preguntas que teníamos:

```
library(ggplot2)
years <- c(1962, 1980, 1990, 2000, 2012)
continents <- c("Europe", "Asia")
gapminder %>%
```

```
  filter(year %in% years & continent %in% continents) %>%
  ggplot(aes(fertility, life_expectancy, col = continent)) +
  geom_point() +
  facet_wrap(~year)
```

Viendo este plot parece que las diferencias entre Asia y Europa han ido desapareciendo con el paso de los años.

Centrémonos ahora sólo en el indicador de fertilidad de un pais, USA:

```
gapminder %>%
  filter(country == "United States") %>%
  ggplot(aes(year,fertility)) +
  geom_line()
```

```
## Warning: Removed 1 rows containing missing values (geom_path).
```

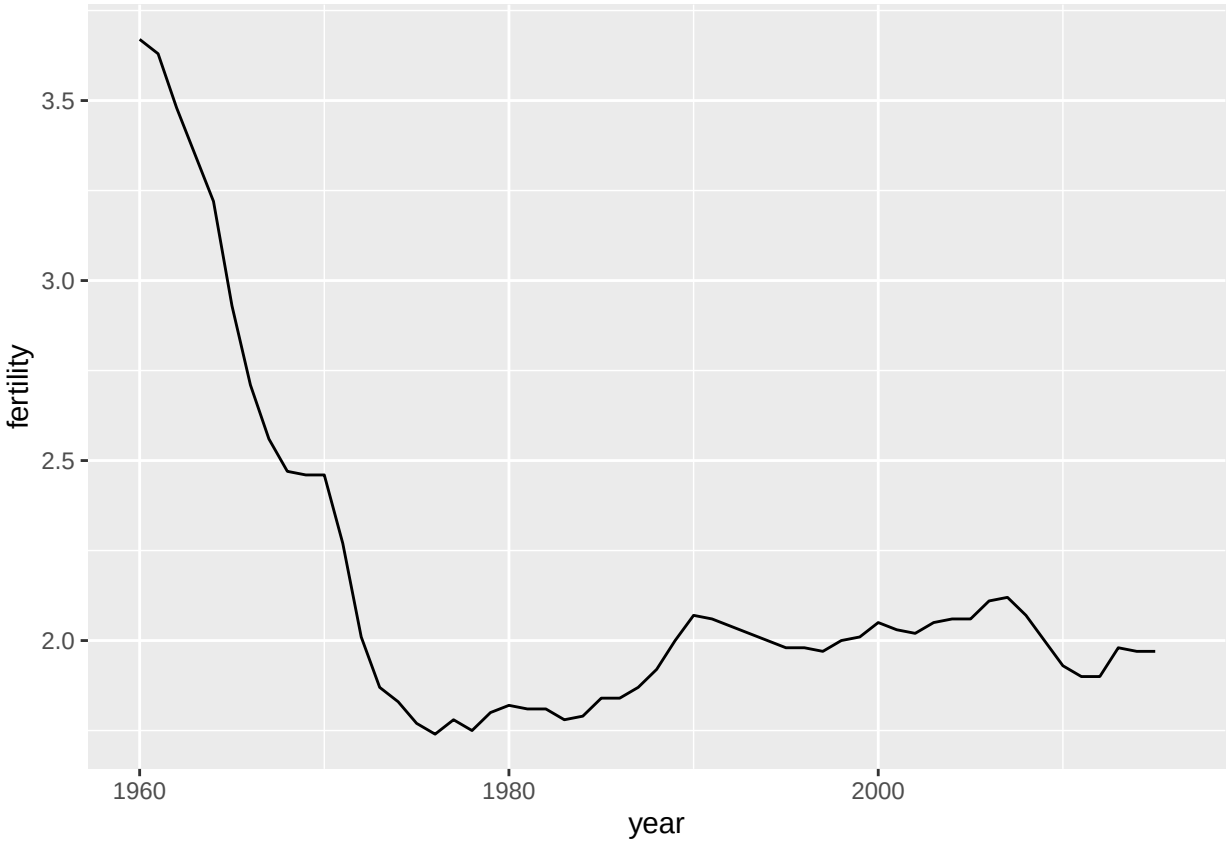

Centrémonos en comparar Alemania y South Korea

```
tidy_data <- gapminder %>%
  filter(country %in%
         c("South Korea", "Germany","United States")) %>%
  select(country, year, fertility)

head(tidy_data)
```

```
##         country year fertility
## 1       Germany 1960      2.41
## 2   South Korea 1960      6.16
## 3 United States 1960      3.67
## 4       Germany 1961      2.44
## 5   South Korea 1961      5.99
## 6 United States 1961      3.63
```

```
tidy_data %>%
  ggplot(aes(year, fertility, color = country)) +
  geom_point()
```

```
## Warning: Removed 3 rows containing missing values (geom_point).
```

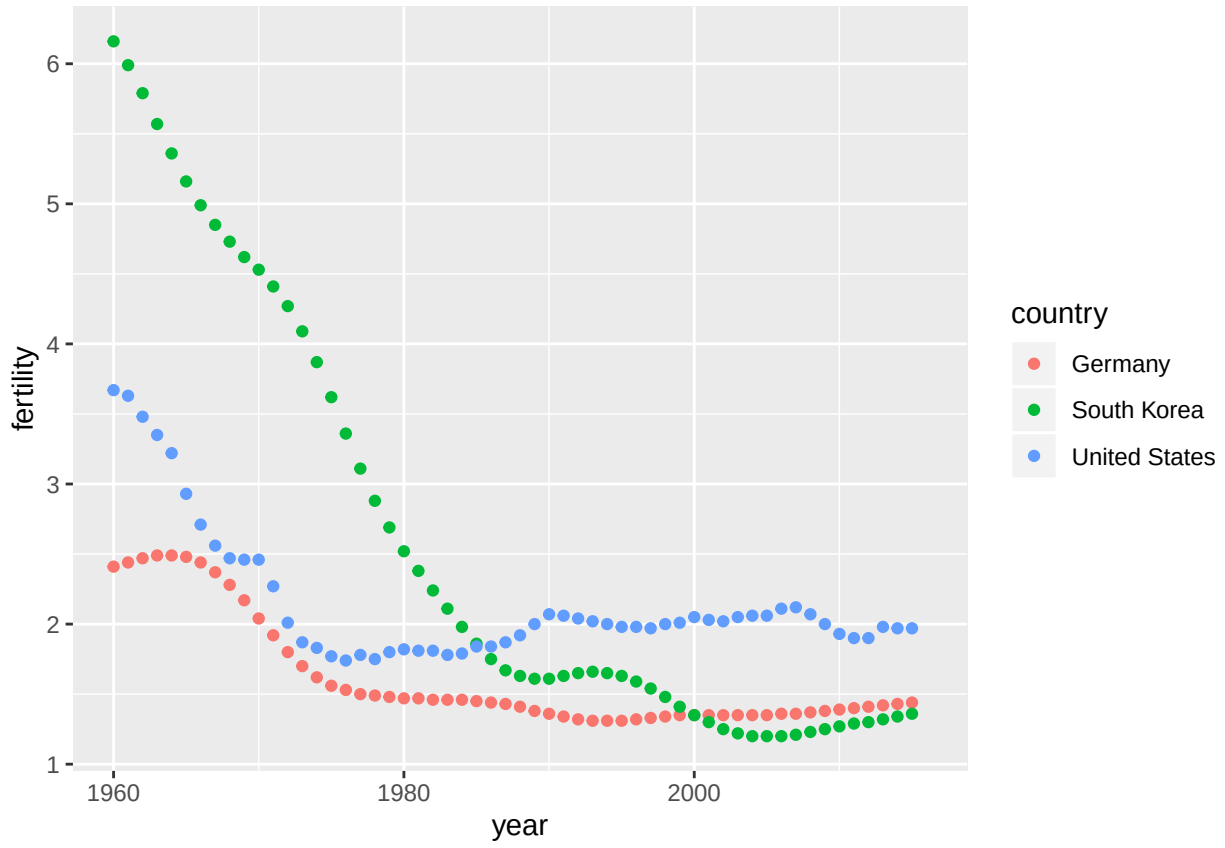

pivot_longer* and *pivot_wider

Todo esto ha sido posible porque gapminder contiene la información en un formato tidy. Irizarry y sus colegas han hecho un gran esfuerzo para poder tener los datos limpios y en este formato. Cómo podemos transformar datos *wide* en datos *tidy*? Utilizando la función *gather* o mejor aun, su sustituta *pivot_longer()*

Primero leemos los datos en formato *tibble*.

```
path <- system.file("extdata", package="dslabs")
filename <- file.path(path,  "fertility-two-countries-example.csv")
wide_data <- read_csv(filename)
```

```
## Parsed with column specification:
## cols(
##   .default = col_double(),
##   country = col_character()
## )
```

```
## See spec(...) for full column specifications.
```

```
wide_data
```

```
## # A tibble: 2 x 57
##   country `1960` `1961` `1962` `1963` `1964` `1965` `1966` `1967` `1968`
##   <chr>    <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>
## 1 Germany   2.41   2.44   2.47   2.49   2.49   2.48   2.44   2.37   2.28
## 2 South ~   6.16   5.99   5.79   5.57   5.36   5.16   4.99   4.85   4.73
## # ... with 47 more variables: `1969` <dbl>, `1970` <dbl>, `1971` <dbl>,
## #   `1972` <dbl>, `1973` <dbl>, `1974` <dbl>, `1975` <dbl>, `1976` <dbl>,
```

```
## #   `1977` <dbl>, `1978` <dbl>, `1979` <dbl>, `1980` <dbl>, `1981` <dbl>,
## #   `1982` <dbl>, `1983` <dbl>, `1984` <dbl>, `1985` <dbl>, `1986` <dbl>,
## #   `1987` <dbl>, `1988` <dbl>, `1989` <dbl>, `1990` <dbl>, `1991` <dbl>,
## #   `1992` <dbl>, `1993` <dbl>, `1994` <dbl>, `1995` <dbl>, `1996` <dbl>,
## #   `1997` <dbl>, `1998` <dbl>, `1999` <dbl>, `2000` <dbl>, `2001` <dbl>,
## #   `2002` <dbl>, `2003` <dbl>, `2004` <dbl>, `2005` <dbl>, `2006` <dbl>,
## #   `2007` <dbl>, `2008` <dbl>, `2009` <dbl>, `2010` <dbl>, `2011` <dbl>,
## #   `2012` <dbl>, `2013` <dbl>, `2014` <dbl>, `2015` <dbl>
```

```
#como ejemplo: seleccionamos las primeras 9 columnas por nombre
select(wide_data, country, `1960`:`1967`)
```

```
## # A tibble: 2 x 9
##   country     `1960` `1961` `1962` `1963` `1964` `1965` `1966` `1967`
##   <chr>        <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>
## 1 Germany       2.41   2.44   2.47   2.49   2.49   2.48   2.44   2.37
## 2 South Korea   6.16   5.99   5.79   5.57   5.36   5.16   4.99   4.85
```

La funcion *pivot_longer()* va a "normalizar" los datos en las columnas que le digamos (`1960:2015`) preservando la información del resto de columnas de la matriz. Los primeros valores que le damos es el nombre del "key" y el nombre para el "value"

```
new_tidy_data <- wide_data %>%
  pivot_longer(-country,
               names_to = "year",
               values_to = "fertility")
class(new_tidy_data$year)
```

```
## [1] "character"
```

A veces se necesita volver de tidy data a wide data usando *pivot_wider()*

```
new_wide_data <- new_tidy_data %>%
  pivot_wider(names_from=year, values_from=fertility)
select(new_wide_data, country, `1960`:`1967`)
```

```
## # A tibble: 2 x 9
##   country     `1960` `1961` `1962` `1963` `1964` `1965` `1966` `1967`
##   <chr>        <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>  <dbl>
## 1 Germany       2.41   2.44   2.47   2.49   2.49   2.48   2.44   2.37
## 2 South Korea   6.16   5.99   5.79   5.57   5.36   5.16   4.99   4.85
```

Si los nombres de las columnas son numericos

```
billboard
```

```
## # A tibble: 317 x 79
##    artist track date.entered   wk1   wk2   wk3   wk4   wk5   wk6   wk7
##    <chr>  <chr> <date>       <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
##  1 2 Pac  Baby~ 2000-02-26      87    82    72    77    87    94    99
##  2 2Ge+h~ The ~ 2000-09-02      91    87    92    NA    NA    NA    NA
##  3 3 Doo~ Kryp~ 2000-04-08      81    70    68    67    66    57    54
##  4 3 Doo~ Loser 2000-10-21      76    76    72    69    67    65    55
##  5 504 B~ Wobb~ 2000-04-15      57    34    25    17    17    31    36
##  6 98^0   Give~ 2000-08-19      51    39    34    26    26    19     2
##  7 A*Tee~ Danc~ 2000-07-08      97    97    96    95   100    NA    NA
##  8 Aaliy~ I Do~ 2000-01-29      84    62    51    41    38    35    35
##  9 Aaliy~ Try ~ 2000-03-18      59    53    38    28    21    18    16
```

```
## 10 Adams~ Open~ 2000-08-26      76    76    74    69    68    67    61
## # ... with 307 more rows, and 69 more variables: wk8 <dbl>, wk9 <dbl>,
## #   wk10 <dbl>, wk11 <dbl>, wk12 <dbl>, wk13 <dbl>, wk14 <dbl>,
## #   wk15 <dbl>, wk16 <dbl>, wk17 <dbl>, wk18 <dbl>, wk19 <dbl>,
## #   wk20 <dbl>, wk21 <dbl>, wk22 <dbl>, wk23 <dbl>, wk24 <dbl>,
## #   wk25 <dbl>, wk26 <dbl>, wk27 <dbl>, wk28 <dbl>, wk29 <dbl>,
## #   wk30 <dbl>, wk31 <dbl>, wk32 <dbl>, wk33 <dbl>, wk34 <dbl>,
## #   wk35 <dbl>, wk36 <dbl>, wk37 <dbl>, wk38 <dbl>, wk39 <dbl>,
## #   wk40 <dbl>, wk41 <dbl>, wk42 <dbl>, wk43 <dbl>, wk44 <dbl>,
## #   wk45 <dbl>, wk46 <dbl>, wk47 <dbl>, wk48 <dbl>, wk49 <dbl>,
## #   wk50 <dbl>, wk51 <dbl>, wk52 <dbl>, wk53 <dbl>, wk54 <dbl>,
## #   wk55 <dbl>, wk56 <dbl>, wk57 <dbl>, wk58 <dbl>, wk59 <dbl>,
## #   wk60 <dbl>, wk61 <dbl>, wk62 <dbl>, wk63 <dbl>, wk64 <dbl>,
## #   wk65 <dbl>, wk66 <lgl>, wk67 <lgl>, wk68 <lgl>, wk69 <lgl>,
## #   wk70 <lgl>, wk71 <lgl>, wk72 <lgl>, wk73 <lgl>, wk74 <lgl>,
## #   wk75 <lgl>, wk76 <lgl>
```

```
billboard %>%
  pivot_longer(
    cols = starts_with("wk"),
    names_to = "week",
    values_to = "rank",
    values_drop_na = TRUE
  )
```

```
## # A tibble: 5,307 x 5
##    artist  track                   date.entered week   rank
##    <chr>   <chr>                   <date>       <chr> <dbl>
##  1 2 Pac   Baby Don't Cry (Keep... 2000-02-26   wk1      87
##  2 2 Pac   Baby Don't Cry (Keep... 2000-02-26   wk2      82
##  3 2 Pac   Baby Don't Cry (Keep... 2000-02-26   wk3      72
##  4 2 Pac   Baby Don't Cry (Keep... 2000-02-26   wk4      77
##  5 2 Pac   Baby Don't Cry (Keep... 2000-02-26   wk5      87
##  6 2 Pac   Baby Don't Cry (Keep... 2000-02-26   wk6      94
##  7 2 Pac   Baby Don't Cry (Keep... 2000-02-26   wk7      99
##  8 2Ge+her The Hardest Part Of ... 2000-09-02   wk1      91
##  9 2Ge+her The Hardest Part Of ... 2000-09-02   wk2      87
## 10 2Ge+her The Hardest Part Of ... 2000-09-02   wk3      92
## # ... with 5,297 more rows
```

Ahora queremos convertir la variable semana en numerica

```
billboard %>%
  pivot_longer(
    cols = starts_with("wk"),
    names_to = "week",
    names_prefix = "wk",
    names_ptypes = list(week = integer()),
    values_to = "rank",
    values_drop_na = TRUE
  )
```

```
## # A tibble: 5,307 x 5
##    artist  track                   date.entered  week  rank
##    <chr>   <chr>                   <date>       <int> <dbl>
##  1 2 Pac   Baby Don't Cry (Keep... 2000-02-26       1    87
```

```
##  2 2 Pac   Baby Don't Cry (Keep... 2000-02-26       2    82
##  3 2 Pac   Baby Don't Cry (Keep... 2000-02-26       3    72
##  4 2 Pac   Baby Don't Cry (Keep... 2000-02-26       4    77
##  5 2 Pac   Baby Don't Cry (Keep... 2000-02-26       5    87
##  6 2 Pac   Baby Don't Cry (Keep... 2000-02-26       6    94
##  7 2 Pac   Baby Don't Cry (Keep... 2000-02-26       7    99
##  8 2Ge+her The Hardest Part Of ... 2000-09-02       1    91
##  9 2Ge+her The Hardest Part Of ... 2000-09-02       2    87
## 10 2Ge+her The Hardest Part Of ... 2000-09-02       3    92
## # ... with 5,297 more rows
```

```
billboard %>%
  pivot_longer(
    cols = starts_with("wk"),
    names_to = "week",
    names_prefix = "wk",
    names_ptypes = list(week = integer()),
    values_to = "rank",
    values_drop_na = TRUE)%>%
  select(week)
```

```
## # A tibble: 5,307 x 1
##     week
##    <int>
##  1     1
##  2     2
##  3     3
##  4     4
##  5     5
##  6     6
##  7     7
##  8     1
##  9     2
## 10     3
## # ... with 5,297 more rows
```

Variables dentro de los nombres de columna

```
who
```

```
## # A tibble: 7,240 x 60
##    country iso2  iso3   year new_sp_m014 new_sp_m1524 new_sp_m2534
##    <chr>   <chr> <chr> <int>       <int>        <int>        <int>
##  1 Afghan~ AF    AFG    1980          NA           NA           NA
##  2 Afghan~ AF    AFG    1981          NA           NA           NA
##  3 Afghan~ AF    AFG    1982          NA           NA           NA
##  4 Afghan~ AF    AFG    1983          NA           NA           NA
##  5 Afghan~ AF    AFG    1984          NA           NA           NA
##  6 Afghan~ AF    AFG    1985          NA           NA           NA
##  7 Afghan~ AF    AFG    1986          NA           NA           NA
##  8 Afghan~ AF    AFG    1987          NA           NA           NA
##  9 Afghan~ AF    AFG    1988          NA           NA           NA
## 10 Afghan~ AF    AFG    1989          NA           NA           NA
## # ... with 7,230 more rows, and 53 more variables: new_sp_m3544 <int>,
## #   new_sp_m4554 <int>, new_sp_m5564 <int>, new_sp_m65 <int>,
## #   new_sp_f014 <int>, new_sp_f1524 <int>, new_sp_f2534 <int>,
```

```
## #   new_sp_f3544 <int>, new_sp_f4554 <int>, new_sp_f5564 <int>,
## #   new_sp_f65 <int>, new_sn_m014 <int>, new_sn_m1524 <int>,
## #   new_sn_m2534 <int>, new_sn_m3544 <int>, new_sn_m4554 <int>,
## #   new_sn_m5564 <int>, new_sn_m65 <int>, new_sn_f014 <int>,
## #   new_sn_f1524 <int>, new_sn_f2534 <int>, new_sn_f3544 <int>,
## #   new_sn_f4554 <int>, new_sn_f5564 <int>, new_sn_f65 <int>,
## #   new_ep_m014 <int>, new_ep_m1524 <int>, new_ep_m2534 <int>,
## #   new_ep_m3544 <int>, new_ep_m4554 <int>, new_ep_m5564 <int>,
## #   new_ep_m65 <int>, new_ep_f014 <int>, new_ep_f1524 <int>,
## #   new_ep_f2534 <int>, new_ep_f3544 <int>, new_ep_f4554 <int>,
## #   new_ep_f5564 <int>, new_ep_f65 <int>, newrel_m014 <int>,
## #   newrel_m1524 <int>, newrel_m2534 <int>, newrel_m3544 <int>,
## #   newrel_m4554 <int>, newrel_m5564 <int>, newrel_m65 <int>,
## #   newrel_f014 <int>, newrel_f1524 <int>, newrel_f2534 <int>,
## #   newrel_f3544 <int>, newrel_f4554 <int>, newrel_f5564 <int>,
## #   newrel_f65 <int>
```

```
who %>%
pivot_longer(
  cols = new_sp_m014:newrel_f65,
  names_to = c("diagnosis", "gender", "age"),
  names_pattern = "new_?(.*)_(.)(.*)",
  values_to = "count"
)
```

```
## # A tibble: 405,440 x 8
##    country     iso2  iso3   year diagnosis gender age   count
##    <chr>       <chr> <chr> <int> <chr>     <chr>  <chr> <int>
##  1 Afghanistan AF    AFG    1980 sp        m      014      NA
##  2 Afghanistan AF    AFG    1980 sp        m      1524     NA
##  3 Afghanistan AF    AFG    1980 sp        m      2534     NA
##  4 Afghanistan AF    AFG    1980 sp        m      3544     NA
##  5 Afghanistan AF    AFG    1980 sp        m      4554     NA
##  6 Afghanistan AF    AFG    1980 sp        m      5564     NA
##  7 Afghanistan AF    AFG    1980 sp        m      65       NA
##  8 Afghanistan AF    AFG    1980 sp        f      014      NA
##  9 Afghanistan AF    AFG    1980 sp        f      1524     NA
## 10 Afghanistan AF    AFG    1980 sp        f      2534     NA
## # ... with 405,430 more rows
```

```
who %>%
pivot_longer(
  cols = new_sp_m014:newrel_f65,
  names_to = c("diagnosis", "gender", "age"),
  names_pattern = "new_?(.*)_(.)(.*)",
  names_ptypes = list(
    gender = factor(levels = c("f", "m")),
    age = factor(
      levels = c("014", "1524", "2534", "3544", "4554", "5564", "65"),
      ordered = TRUE
    )
  ),
  values_to = "count"
)
```

```
## # A tibble: 405,440 x 8
```

```
##    country     iso2  iso3   year diagnosis gender age   count
##    <chr>       <chr> <chr> <int> <chr>     <fct>  <ord> <int>
##  1 Afghanistan AF    AFG    1980 sp        m      014      NA
##  2 Afghanistan AF    AFG    1980 sp        m      1524     NA
##  3 Afghanistan AF    AFG    1980 sp        m      2534     NA
##  4 Afghanistan AF    AFG    1980 sp        m      3544     NA
##  5 Afghanistan AF    AFG    1980 sp        m      4554     NA
##  6 Afghanistan AF    AFG    1980 sp        m      5564     NA
##  7 Afghanistan AF    AFG    1980 sp        m      65       NA
##  8 Afghanistan AF    AFG    1980 sp        f      014      NA
##  9 Afghanistan AF    AFG    1980 sp        f      1524     NA
## 10 Afghanistan AF    AFG    1980 sp        f      2534     NA
## # ... with 405,430 more rows
```

Varias observaciones por fila

```
View(anscombe)
anscombe %>%
 pivot_longer(everything(),
   names_to = c(".value", "set"),
   names_pattern = "(.)(.)"
 )
```

```
## # A tibble: 44 x 3
##    set       x     y
##    <chr> <dbl> <dbl>
##  1 1        10  8.04
##  2 2        10  9.14
##  3 3        10  7.46
##  4 4         8  6.58
##  5 1         8  6.95
##  6 2         8  8.14
##  7 3         8  6.77
##  8 4         8  5.76
##  9 1        13  7.58
## 10 2        13  8.74
## # ... with 34 more rows
```

Otro ejemplo:

```
path <- system.file("extdata", package = "dslabs")
filename <- file.path(path, "life-expectancy-and-fertility-two-countries-example.csv")

raw_dat <- read_csv(filename)
```

```
## Parsed with column specification:
## cols(
##   .default = col_double(),
##   country = col_character()
## )
```

```
## See spec(...) for full column specifications.
```

```
# lo transformamos en data tidy
dat <- raw_dat %>%
  pivot_longer(-country,
               names_to = "key",
```

```
               values_to="value")
head(dat)
```

```
## # A tibble: 6 x 3
##   country key                  value
##   <chr>   <chr>                <dbl>
## 1 Germany 1960_fertility        2.41
## 2 Germany 1960_life_expectancy 69.3
## 3 Germany 1961_fertility        2.44
## 4 Germany 1961_life_expectancy 69.8
## 5 Germany 1962_fertility        2.47
## 6 Germany 1962_life_expectancy 70.0
```

```
# pero tenemos dos observaciones (año&variable) en cada fila
dat <- raw_dat %>%
  pivot_longer(-country,
               names_to = c("year", "variable"),
               names_pattern = "(.{4})_(.*)",
               names_ptypes = list(
                 year = integer(),
                 variable=factor(
                   levels=c("fertility","life_expectancy"))
                 ),
  values_to = "value"
 )
```

Ejercicios: tidy/wide

1. Niveles de CO2.

Definimos los datos de CO2 en formato wide:

```
#? co2
View(co2)
co2_wide <- data.frame(matrix(co2, ncol = 12, byrow = TRUE)) %>%
  setNames(1:12) %>%
  mutate(year = as.character(1959:1997))
```

Utiliza la función *pivot_longer* para reordenar este objeto en formato *tidy*. Llama CO2 a la columna con las mediciones de co2 y mes a la columna de los meses. El objeto se llamará co2_tidy.

INtentamos usarlo para plotear las series temporales

No es capaz de hacer el plot porque month no es un numérico. Rehaz el objeto asegurandote de que month es numérico.

Que nos dice este plot?

A. Los niveles de CO2 aumentan monotonicamente de 1959 a 1997.

B. Los niveles de CO2 son mas altos en verano y la media anual aumento de 1959 a 1997.

C. Los niveles de CO2 son constantes y variabilidad aleatoria es lo que explica las diferencias.

D. Los niveles de CO2 no tienen una tendencia estacional.

2. Porcentaje de admision de hombres y mujeres Utilizando los datos del paquete dslabs:

```
admissions
```

```
##    major gender admitted applicants
## 1      A    men       62        825
## 2      B    men       63        560
## 3      C    men       37        325
## 4      D    men       33        417
## 5      E    men       28        191
## 6      F    men        6        373
## 7      A  women       82        108
## 8      B  women       68         25
## 9      C  women       34        593
## 10     D  women       35        375
## 11     E  women       24        393
## 12     F  women        7        341
```

- Transformalo usando *pivot_longer()*, una fila para cada major.
- Usa gather para crear un tmp data.frame con una columna que contenga el tipo de información (aplicant/admitted).
- Usa unite para crear la columna column_name i que contenga la informacion de admitted_men, admitted_women, applicants_men and applicants_women
- Usa spread para generar los datos tidy con cuatro variables para cada major
- Usa %>% para escribir una sola linea de codigo que convierta admissions en la tabla tidy final.

3. Tibble family: convierte los datos en tidy

```
family <- tribble(
  ~family,  ~dob_child1,  ~dob_child2, ~gender_child1, ~gender_child2,
       1L, "1998-11-26", "2000-01-29",             1L,             2L,
       2L, "1996-06-22",           NA,             2L,             NA,
       3L, "2002-07-11", "2004-04-05",             2L,             2L,
       4L, "2004-10-10", "2009-08-27",             1L,             1L,
       5L, "2000-12-05", "2005-02-28",             2L,             1L,
)
family
```

```
## # A tibble: 5 x 5
##   family dob_child1 dob_child2 gender_child1 gender_child2
##    <int> <chr>      <chr>              <int>         <int>
## 1      1 1998-11-26 2000-01-29             1             2
## 2      2 1996-06-22 <NA>                   2            NA
## 3      3 2002-07-11 2004-04-05             2             2
## 4      4 2004-10-10 2009-08-27             1             1
## 5      5 2000-12-05 2005-02-28             2             1
```

```
family <- family %>% mutate_at(vars(starts_with("dob")), parse_date)
family
```

```
## # A tibble: 5 x 5
##   family dob_child1 dob_child2 gender_child1 gender_child2
##    <int> <date>     <date>             <int>         <int>
## 1      1 1998-11-26 2000-01-29             1             2
## 2      2 1996-06-22 NA                     2            NA
## 3      3 2002-07-11 2004-04-05             2             2
## 4      4 2004-10-10 2009-08-27             1             1
## 5      5 2000-12-05 2005-02-28             2             1
```

```
## # A tibble: 9 x 4
##   family child  dob        gender
##    <int> <chr>  <date>      <int>
## 1      1 child1 1998-11-26      1
## 2      1 child2 2000-01-29      2
## 3      2 child1 1996-06-22      2
## 4      3 child1 2002-07-11      2
## 5      3 child2 2004-04-05      2
## 6      4 child1 2004-10-10      1
## 7      4 child2 2009-08-27      1
## 8      5 child1 2000-12-05      2
## 9      5 child2 2005-02-28      1
```

Limpieza de datos: el paquete janitor

```
library(janitor)
test_df <- as.data.frame(matrix(ncol = 6))
names(test_df) <- c("firstName", "ábc@!*", "% successful (2009)",
                    "REPEAT VALUE", "REPEAT VALUE", "")

test_df %>%
  clean_names()
```

```
##   first_name abc percent_successful_2009 repeat_value repeat_value_2  x
## 1         NA  NA                      NA           NA             NA NA
```

```
make.names(names(test_df))
```

```
## [1] "firstName"           "ábc..."              "X..successful..2009."
## [4] "REPEAT.VALUE"        "REPEAT.VALUE"        "X"
```

tabyl better than table: adorn_() functions

tabyl es la alternativa en el universo tidyverse a table. Es un tipo de objeto que vais a usar mucho como data scientists. Cuenta combinaciones de 1,2,3 variables de una forma mas eficiente que table. Una vez creada la tabla podemos formatearla como queramos usando adorn_* functions

Problemas de table:

- No acepta data.frame inputs y no combina bien con %>%
- No produce data.frames
- Su resultado es dificil de formatear

tabyl() que forma parte del paquete *janitor* soluciona estos problemas.Ademas funciona con vectores y no cuenta los NAs.

```
x <- c("big", "big", "small", "small", "small", NA)
tabyl(x)
```

```
##       x n   percent valid_percent
##     big 2 0.3333333           0.4
##   small 3 0.5000000           0.6
##    <NA> 1 0.1666667            NA
```

Ejemplo 1: mtcars

```
mtcars %>%
  tabyl(gear, cyl) %>%
  adorn_totals("col") %>%
  adorn_percentages("row") %>%
  adorn_pct_formatting(digits = 2) %>%
  adorn_ns() %>%
  adorn_title()
```

```
##              cyl
##  gear          4          6           8        Total
##     3  6.67% (1) 13.33% (2) 80.00% (12) 100.00% (15)
##     4 66.67% (8) 33.33% (4)  0.00%  (0) 100.00% (12)
##     5 40.00% (2) 20.00% (1) 40.00%  (2) 100.00%  (5)
```

adorn() se puede llamar en todo tipo de objetos, no solo en un tabyl()

```
mtcars %>% adorn_totals("col") %>% adorn_percentages("col") %>% head()
```

```
##   mpg        cyl       disp         hp       drat         wt       qsec
##  21.0 0.03030303 0.02167111 0.02343417 0.03388652 0.02544875 0.02881854
##  21.0 0.03030303 0.02167111 0.02343417 0.03388652 0.02792564 0.02979901
##  22.8 0.02020202 0.01462800 0.01981253 0.03345208 0.02253477 0.03258281
##  21.4 0.03030303 0.03494467 0.02343417 0.02676166 0.03122815 0.03403600
##  18.7 0.04040404 0.04876001 0.03728164 0.02736988 0.03341363 0.02979901
##  18.1 0.03030303 0.03047500 0.02236898 0.02398123 0.03360789 0.03540164
##          vs         am       gear       carb      Total
##  0.00000000 0.07692308 0.03389831 0.04444444 0.02315761
##  0.00000000 0.07692308 0.03389831 0.04444444 0.02321889
##  0.07142857 0.07692308 0.03389831 0.01111111 0.01780394
##  0.07142857 0.00000000 0.02542373 0.01111111 0.03043280
##  0.00000000 0.00000000 0.02542373 0.02222222 0.04298045
##  0.07142857 0.00000000 0.02542373 0.01111111 0.02762852
```

Ejemplo 2: starwars

```
humans <- starwars %>%
  filter(species == "Human")

t1 <- humans %>%
  tabyl(eye_color)
```

```
t1 %>%
  adorn_totals("row") %>%
  adorn_pct_formatting()
```

```
##  eye_color  n percent
##       blue 12   34.3%
##  blue-gray  1    2.9%
##      brown 17   48.6%
##       dark  1    2.9%
##      hazel  2    5.7%
##     yellow  2    5.7%
##      Total 35  100.0%
```

Se pueden ademas producir tablas de contingencia con tabyl

```
t2 <- humans %>%
  tabyl(gender, eye_color)

t2 %>%
  adorn_percentages("row") %>%
  adorn_pct_formatting(digits = 2) %>%
  adorn_ns()
```

```
##  gender       blue blue-gray       brown      dark      hazel    yellow
##  female 33.33% (3) 0.00% (0) 55.56%  (5) 0.00% (0) 11.11% (1) 0.00% (0)
##    male 34.62% (9) 3.85% (1) 46.15% (12) 3.85% (1)  3.85% (1) 7.69% (2)
```

Tablas con 3 variables tabyl

```
t3 <- humans %>%
  tabyl(eye_color, skin_color, gender)
```

```
humans %>%
  tabyl(eye_color, skin_color, gender, show_missing_levels = FALSE) %>%
  adorn_totals("row") %>%
  adorn_percentages("all") %>%
  adorn_pct_formatting(digits = 1) %>%
  adorn_ns %>%
  adorn_title
```

```
## $female
##            skin_color
##  eye_color       fair     light
##       blue  22.2% (2) 11.1% (1)
##      brown  11.1% (1) 44.4% (4)
##      hazel   0.0% (0) 11.1% (1)
##      Total  33.3% (3) 66.7% (6)
##
## $male
##            skin_color
##  eye_color       dark       fair     light     pale      tan    white
##       blue   0.0% (0) 26.9%  (7)  7.7% (2) 0.0% (0) 0.0% (0) 0.0% (0)
##  blue-gray   0.0% (0)  3.8%  (1)  0.0% (0) 0.0% (0) 0.0% (0) 0.0% (0)
##      brown  11.5% (3) 15.4%  (4) 11.5% (3) 0.0% (0) 7.7% (2) 0.0% (0)
##       dark   3.8% (1)  0.0%  (0)  0.0% (0) 0.0% (0) 0.0% (0) 0.0% (0)
##      hazel   0.0% (0)  3.8%  (1)  0.0% (0) 0.0% (0) 0.0% (0) 0.0% (0)
##     yellow   0.0% (0)  0.0%  (0)  0.0% (0) 3.8% (1) 0.0% (0) 3.8% (1)
##      Total  15.4% (4) 50.0% (13) 19.2% (5) 3.8% (1) 7.7% (2) 3.8% (1)
```

Se pueden presentar tablas de manera incluso mas elegante usando kable del paquete knitr

```
humans %>%
  tabyl(gender, eye_color) %>%
  adorn_totals(c("row", "col")) %>%
  adorn_percentages("row") %>%
  adorn_pct_formatting(rounding = "half up", digits = 0) %>%
  adorn_ns() %>%
  adorn_title("combined") %>%
  knitr::kable()
```

gender/eye_color	blue	blue-gray	brown	dark	hazel	yellow	Total
female	33% (3)	0% (0)	56% (5)	0% (0)	11% (1)	0% (0)	100% (9)
male	35% (9)	4% (1)	46% (12)	4% (1)	4% (1)	8% (2)	100% (26)
Total	34% (12)	3% (1)	49% (17)	3% (1)	6% (2)	6% (2)	100% (35)

Ejemplo 3: Modelos de coches

```
mpg_by_cyl_and_am <- mtcars %>%
  group_by(cyl, am) %>%
  summarise(mpg = mean(mpg)) %>%
  spread(am, mpg)

mpg_by_cyl_and_am
```

```
## # A tibble: 3 x 3
## # Groups:   cyl [3]
##     cyl   `0`   `1`
##   <dbl> <dbl> <dbl>
## 1     4  22.9  28.1
## 2     6  19.1  20.6
## 3     8  15.0  15.4
```

```
mpg_by_cyl_and_am %>%
  adorn_rounding() %>%
  adorn_ns(
    ns = mtcars %>% # calculate the Ns on the fly by calling tabyl on the original data
      tabyl(cyl, am)
  ) %>%
  adorn_title("combined", row_name = "Cylinders", col_name = "Is Automatic")
```

```
##   Cylinders/Is Automatic         0        1
## 1                      4 22.9  (3) 28.1 (8)
## 2                      6 19.1  (4) 20.6 (3)
## 3                      8 15.1 (12) 15.4 (2)
```

Otras funciones del paquete janitor

get_dupes()

```
get_dupes(mtcars, wt, cyl)
```

```
## # A tibble: 4 x 12
##      wt   cyl dupe_count   mpg  disp    hp  drat  qsec    vs    am  gear
##   <dbl> <dbl>      <int> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1  3.44     6          2  19.2  168.   123  3.92  18.3     1     0     4
## 2  3.44     6          2  17.8  168.   123  3.92  18.9     1     0     4
## 3  3.57     8          2  14.3  360    245  3.21  15.8     0     0     3
## 4  3.57     8          2  15    301    335  3.54  14.6     0     1     5
## # ... with 1 more variable: carb <dbl>
```

get_dupes()

```
# remove_empty() rows and columns
```

```
q <- data.frame(v1 = c(1, NA, 3),
                v2 = c(NA, NA, NA),
                v3 = c("a", NA, "b"))
q %>%
  remove_empty(c("rows", "cols"))
```

```
##   v1 v3
## 1  1  a
## 3  3  b
```

round_half_up()

```
nums <- c(2.5, 3.5)
round(nums)
```

```
## [1] 2 4
```

```
round_half_up(nums)
```

```
## [1] 3 4
```

factores

```
# Count factor levels in groups of high, medium, and low with top_levels()

f <- factor(
  c("strongly agree", "agree", "neutral", "neutral", "disagree", "strongly agree"),
  levels = c("strongly agree", "agree", "neutral", "disagree", "strongly disagree"))
top_levels(f)
```

```
##                             f n   percent
##        strongly agree, agree 3 0.5000000
##                      neutral 2 0.3333333
##  disagree, strongly disagree 1 0.1666667
```

```
top_levels(f, n = 1)
```

```
##                          f n   percent
##            strongly agree 2 0.3333333
##  agree, neutral, disagree 4 0.6666667
##         strongly disagree 0 0.0000000
```

Map-reduce using R

```
library(purrr)
mtcars %>%
  split(.$cyl) %>% # from base R
  map(~ lm(mpg ~ wt, data = .)) %>%
  map(summary) %>%
  map_dbl("r.squared")
```

```
##         4         6         8
## 0.5086326 0.4645102 0.4229655
```